

25. 12. 07

강화학습의 기초 - 팀 프로젝트 보고서

논문 교정 AI 에이전트 최적화 강화학습

서강대학교 AI · SW 대학원 데이터사이언스 · 인공지능전공

A72040 김진산 | A72080 차시명 | A72085 한다현

팀명 : 외유내강 (겉으론 부드러워 보이나, 내가 강화되고 있음)

<https://github.com/itcasim0/reinforcement-with-lm>

CONTENTS

1. 프로젝트 개요

- 주제
- 목표
- 문제 정의
- 핵심 과제

2. 강화학습 환경

- 학습 프로세스
- state
- action
- reward

3. 데이터셋

- 원문 및 재가공 데이터
- 오프라인 데이터셋

4. 실험 개요

- 실험 방법
- 알고리즘
- 모델 구조
- 환경 및 설정
- 강화학습 성능 지표
- 입력 데이터 흐름

5. 실험

- 실험 1 : 오프라인 PPO
- 실험 2 : 온라인 PPO
- 실험 3 : 온라인 A2C
- 실험 4 : 온라인 DQN

6. 결론

- 토의
- 결론
- 향후 발전 방향

7. 부록

- 참고 문헌
- 팀원 역할

프로젝트 개요

주제 및 목표



프로젝트 주제

- LLM 기반 논문 교정 AI 에이전트의 **최적화를 위한 강화학습**

프로젝트 목표

- 논문 교정을 위한 다양한 AI 에이전트 간의 상호작용을 **강화학습을 통해 자동화**
- 정확성, 속도, 비용을 **균형적으로 최적화**
- 상황에 맞는 **최적의 교정 액션** 학습

프로젝트 개요

문제 정의

배경

- 최근 LLM 기반의 AI 에이전트 서비스 또는 시스템이 많이 개발되고 있음
- AI 에이전트 서비스란, 특정 작업에 대해 다양한 AI 에이전트 간의 상호작용을 통하여 사용자가 원하는 결과를 가져다 주는 서비스
- 이러한 상호작용을 효과적으로 이끌어내는 것이 서비스 성공의 핵심

서비스 구조

- 본 프로젝트는 논문을 교정하는 AI 에이전트 서비스에 초점을 맞춤
- 문법 교정, 명확성 개선, 간결성 등 다양한 교정 작업에 특화되어 있는 에이전트가 입력된 논문을 순차적으로 작업하여 품질 개선 진행

문제 구조

- 한 번의 프롬프팅으로 교정하는 방식이 아닌, 논문 상태에 따라 여러 교정 작업 중 하나를 단계적으로 선택하는 방식으로 접근함
- 이러한 단계적 작업 선택 과정을 강화학습으로 학습해, 각 단계에서 가장 적합한 작업을 고르는 정책을 모델이 익힘

프로젝트 개요

핵심 과제



효율

LLM 교정 작업의 비용 (API 비용),
레이턴시를 고려한 효율적인 전략 학습



최적

여러 교정 작업의 조합 및 순서 최적화




자동

논문 품질 평가 지표를 기반으로 한
자동화된 의사결정

강화학습 환경

학습 프로세스



- ① 교정 전 논문을 적절한 평가 기준에 따라 품질 점수 도출
- ② 품질 점수를 포함한 state로 학습된 정책을 사용하여 action 결정
- ③ action에 따라 교정 된 논문 재평가

- ④ 1~3 과정을 반복하다가, stop 조건에 따라 에피소드를 종료하고 최종 보상 도출
stop 조건 1 : stop editing action 선택
2 : 최대 스텝 수 도달 (max = 3)
3 : 품질 임계값 도달 (전체 품질 ≥ 9.5)
- ⑤ 최종 보상에 따라 정책 업데이트 진행


강화학습 환경

state

state 차원 : 논문 품질 점수 + 현재 진행 단계 + 이전 액션

Structure (구조적 완성도)

- ✓ 핵심 구성요소(배경·방법·결과)의 균형
- ✓ 문단 간 자연스럽고 일관된 논리 흐름




Academic Style (학술적 스타일)

- ✓ 형식적·객관적 문체 유지
- ✓ 구어체·비학술적 표현 배제



Length (문장 길이)

- ✓ 문장당 평균 길이의 적절성
- ✓ 과도하게 긴 문장에 대한 패널티



Clarity (명확성)

- ✓ 모호한 표현 없이 명확한 의미 전달
- ✓ 불필요한 반복 및 애매한 문장 제거



Information Density (정보 밀도)

- ✓ 핵심 정보·개념의 압축도
- ✓ 불필요한 수식어·중복 표현 제거



Overall (전체 품질)

- ✓ 상위 항목 가중치를 반영한 종합 점수
- ✓ 초록 전반적 완성도 평가

강화학습 환경

state

state 차원 : 논문 품질 점수 + 현재 진행 단계 + 이전 액션

▶ 정규화된 현재 스텝

- step_idx / max_steps : 현재 스텝을 전체 스텝 수로 나눈 값 (0~1 범위)
- 스텝이 길어지는 것을 방지하기 위함

추가정보

이전 액션

현재 진행 단계

▶ 이전 액션의 원-핫 인코딩

- 직전 스텝에서 어떤 액션을 수행했는지 표시하는 벡터
- 같은 액션 반복 수행을 방지하기 위함

강화학습 환경

action

에이전트는 입력된 논문을 수정하기 위해 6개 중 1개의 프롬프트 전략 선택

fix_grammar

문법/맞춤법 오류 교정

01

improve_clarity

표현/구조의 명확성 개선

02

make_concise

중복/군더더기 제거 + 간결화

03

improve_structure

논리 흐름과 같은 구조 개선

04

make_academic

학술적 표현으로 변경

05

stop_editing

교정 종료

06

강화학습 환경

reward

Step Reward (step 마다 보상)

Terminal Reward

품질 변화량 보상

- 각 평가 지표의 변화량 $\div 2$
(10점 스케일 조정을 위함)
- 6개 지표의 평균 계산
- 개선 시 : 변화량 그대로
- 악화 시 : $-0.2 \times |\text{변화량}|$

비용 패널티

- $\text{cost_lambda} \times \text{used_cost_usd}$
- 기본 $\text{cost_lambda} = 1.0$

step 패널티

- $\text{current_step} \times \text{step_penalty}$
- 기본 $\text{step_penalty} = 0.1$

반복 패널티


- 예피소드 내 동일 액션
재사용시 : $-\text{repeat_penalty}$
- 기본 $\text{repeat_penalty} = 0.2$

종료 보상

- $\text{terminal_reward} = (\text{avg_score} - 5.0) \div 5.0$
(-1.0~1.0 범위)
- 5개 평가 기준의
평균(overall)이
5.0보다 높으면 양수 보상,
5.0보다 낮으면 음수 보상

데이터셋

원문 및 재가공 데이터



원문

교정이 필요한 실제 논문 데이터를 확보하기 어려워
국내 논문 초록 500건을 크롤링하여 사용
→ 500건 통계 분석을 통해 품질 평가 기준에도 활용

재가공

원문 논문 초록을 LLM(GPT-4o-mini)을 사용하여 재가공 진행
→ 의도적으로 품질을 낮춘 **저품질 텍스트 데이터셋**으로 변환

저품질화 방법

1. 문법, 맞춤법, 시제 오류 삽입
2. 모호한 표현 삽입 ex) 일지도 모르는, 같은 것 등
3. 어색한 종결어미 사용 ex) 인 것이다. 하는 바이다 등
4. 구어체, 감정적 표현 추가 ex) 사실, 굉장히 등
5. 불필요한 수식어 삽입 ex) 매우, 약간 등

오프라인 데이터셋

데이터 생성 파이프라인

매번 학습할 때마다 LLM API를 호출할 경우,
비용이 많이 들고 학습 시간이 오래 걸림
**최초 1회만 API를 호출하여 오프라인 학습용 데이터셋을
구축한 뒤 이를 기반으로 지속적인 튜닝, 재설계, 학습 진행**

1. 원본 초록 선택
2. 사용 가능한 액션 조합 생성 (길이 1~3)
액션 5개 기준 : $5^1 + 5^2 + 5^3 = 155\text{개 시퀀스}$
3. 각 액션 시퀀스를 순차적으로 적용하여 데이터 생성
4. 하나의 원본 데이터는 JSONL 형태로 시퀀스를 가짐
5. 각 시퀀스는 원문, 액션 조합, 단계별 교정 결과,
비용 정보 포함

데이터셋

오프라인 데이터



실험 개요

실험 방법

학습 패러다임

MLP 기반의 오프라인 학습 / 온라인 학습

- LLM을 파인튜닝하는 강화학습은 고비용이기 때문에 비용을 줄이기 위해 MLP로 정책을 설계하고자 함
- 또한, Action에서 사용하는 LLM도 시간 및 비용이 많이 소모되므로, 2가지의 학습 방법을 중심으로 다양한 실험을 해보고자 함
- 오프라인 학습
 - 학습 시 LLM을 매번 호출하는 것은 시간과 비용이 많이 소모됨
 - 미리 생성된 Trajectory를 활용하여 시뮬레이션 속도를 높이고 샘플 효율성을 확보
- 온라인 학습 (하이브리드 학습)
 - 오프라인 학습을 통해 어느 정도 정의된 환경을 기반으로 온라인 학습 진행
 - 온라인 학습 시 도출되는 Trajectory를 캐시에 저장하여 동일 상황에서 재사용 진행
 - 동일한 조합이 발생하면 LLM 호출 없이 캐시 결과를 바로 사용
 - 불필요한 호출을 줄여 온라인 학습 비용 절감

실험 개요

알고리즘

PPO

Proximal Policy Optimization

- Clipping을 적용해 정책 업데이트 폭을 제한하고 안정적으로 학습
- Actor-Critic 구조로 정책(Actor)과 가치 함수(Critic)를 함께 학습
- 확률적 정책 기반 방식으로 수렴 과정이 비교적 안정적이고 재현성이 높음
- 환경 상호작용 비용이 높거나 파괴적 업데이트가 위험한 상황에서 적합

A2C

Advantage Actor-Critic

- Advantage 기반 정책 업데이트로 효율적으로 학습 수행
- 구조가 단순하고 구현이 쉬우며 병렬 환경에서 학습 속도가 빠름
- Actor-Critic 방식이지만 업데이트 안정화 장치는 상대적으로 단순
- 빠르게 시도하고 baseline을 구축하기 적합

DQN

Deep Q-Network


- 정책을 직접 학습하지 않고 Q-value를 학습하는 가치 기반 방식
- Replay Buffer와 Target Network로 데이터 효율성과 안정성 확보
- 이산적 행동 공간에서 높은 성능 발휘
- 연속 행동 공간에서는 적용을 위해 추가 기법 또는 변형 모델 필요

실험 개요


모델 구조

인공신경망 구조

(PPO, A2C)



DQN 구조



실험 개요

환경 및 설정

01

하드웨어 / 소프트웨어 환경

- OS : Windows 10
- Python : 3.x
- 주요 라이브러리 : pyTorch, OpenAI SDK (LLM API)
- GPU : CUDA 지원 시 GPU 사용, 미지원 시 CPU 사용

02

모델 설정

- 문서 교정 모델 : Qwen3-8B
- 문서 평가 모델 : 룰 기반 평가기

03

체크포인트 및 로깅

- 체크포인트 저장 : 에피소드 별 모델 저장
- Trajectory 저장 : 에피소드별 상세 정보 JSON 저장
- 최고 성능 추적 : Best checkpoint 별도 저장

실험 개요

환경 및 설정

04

환경 파라미터 설정

- terminal_threshold : 9.5 (종료 판단 품질 임계값)
- cost_lambda : 1.0 (LLM 비용 패널티 가중치)
- repeat_penalty : 0.5 (반복 행동 감점)
- step_penalty : 0.1 (스텝 증가 패널티)
- editor_model : qwen3-8b (논문 교정용 LLM)

실험 개요

강화학습 성능 지표

에피소드별 최종 품질



Episode Return

에피소드당 누적 보상

평균 품질 점수





LLM 비용

에피소드당 호출 비용



선택된 액션의 다양성 및 반복률

액션 효율성



수렴 속도

학습 안정화까지 소요 에피소드 수

실험 개요

입력 데이터 흐름

원본

STEP 1

STEP 2

STEP 3

초기 문장

뭐랄까, 이 글는 장애인
취업과 관련된 어떤 느낌을
다룬 것 같아. 글쎄,(중략...)
그래서인지 직장 경험이나
임금 같은 게 중요하다고
하더라. (중략...)

improve_structure

장애인 취업과 관련된 어떤
느낌을 다룬 것 같아. 이에
앞서 선행연구들에서는
직장 경험이나 임금 같은
요소들이 중요할 수 있다고
말하고 있어. (중략 ...)

make_academic

장애인의 취업에 대한
주관적 인식에 대한 연구가
이루어지고 있다. 이에
앞서 선행 연구에서는 직장
경험이나 임금과 같은
요소들이 중요한 역할을 할
수 있다고 제시하고 있다.
(중략 ...)

stop_editing

교정 종료 및 마지막 교정
데이터 output으로 반환

실험

실험 1 : 오프라인 PPO

학습 하이퍼파라미터


- num_episodes : 1000 (총 학습 에피소드 수)
- Batch Size : 3
- Buffer Size : 3
- Learning Rate: 0.003
- Max Steps : 3 (에피소드 당 최대 스텝 횟수)
- Gamma : 0.95 (스텝당 보상 할인율)
- GAE Lamda : 0.95
- Clip Epsilon : 0.2 (PPO Clip Ratio)
- Entropy Coefficient : 0.01
- K Epochs : 3 (배치 재사용 횟수)
- Output Activation : softmax (action 확률 분포)

loss 함수

- $\text{Loss} = L_{\text{actor}} + 0.5 \cdot L_{\text{critic}} - 0.01 \cdot H$
- Actor Loss : Clipped PPO Objective
(정책이 급격하게 바뀌는 것 방지)
$$L_{\text{actor}} = -E_t[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$
- Critic Loss : Value Function Loss
(상태의 실제 return 과 예측 value 간 오차 (MSE))
$$L_{\text{critic}} = (V_{\theta}(s_t) - R_t)^2$$
- Entropy : Exploration Term
(정책의 엔트로피(탐험 장려))

실험

실험 1 : 오프라인 PPO



- ✓ 5개의 데이터셋을 사용하여 PPO 알고리즘으로 오프라인 학습 진행
- ✓ 설계된 환경의 구성 요소 (상태 정의, 보상 형태, 액션 구성)가 실제 학습 과정에서 정상적으로 작동하는지 사전에 검증하고자 배치사이즈와 버퍼사이즈도 작게 설정함
- ✓ 최종적으로 학습 가능성을 확인하여, 데이터 및 step 수를 확장한 후속 실험 진행

실험

실험 2 : 온라인 PPO

학습 하이퍼파라미터


- num_episodes : 1000 (총 학습 에피소드 수)
- Batch Size : 16
- Buffer Size : 32
- Learning Rate: 0.003
- Max Steps : 5 (에피소드 당 최대 스텝 횟수)
- Gamma : 0.95 (스텝당 보상 할인율)
- GAE Lamda : 0.95
- Clip Epsilon : 0.2 (PPO Clip Ratio)
- Entropy Coefficient : 0.03
- K Epochs : 3 (배치 재사용 횟수)
- Output Activation : softmax (action 확률 분포)

loss 함수

- $\text{Loss} = L_{\text{actor}} + 0.5 \cdot L_{\text{critic}} - 0.01 \cdot H$
- Actor Loss : Clipped PPO Objective
(정책이 급격하게 바뀌는 것 방지)
$$L_{\text{actor}} = -E_t[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$
- Critic Loss : Value Function Loss
(상태의 실제 return 과 예측 value 간 오차 (MSE))
$$L_{\text{critic}} = (V_{\theta}(s_t) - R_t)^2$$
- Entropy : Exploration Term
(정책의 엔트로피(탐험 장려))

실험

실험 2 : 온라인 PPO



- ✓ 50개의 데이터셋을 사용하여 PPO 알고리즘으로 온라인 학습 진행
- ✓ PPO 특성상, 새로운 데이터를 지속해서 수집해야 하므로 배치사이즈와 step 규모가 커질수록 부담스러움
- ✓ 1000개의 Episode에서는 많은 결과를 가져오지 못함

실험

실험 3 : 온라인 A2C

학습 하이퍼파라미터


- num_episodes : 1000 (총 학습 에피소드 수)
- Learning Rate: 0.003
- Max Steps : 5 (에피소드 당 최대 스텝 횟수)
- Gamma : 0.95 (스텝당 보상 할인율)
- GAE Lamda : 0.95
- Entropy Coefficient : 0.03
- K Epochs : 3 (배치 재사용 횟수)
- Output Activation : softmax (action 확률 분포)

loss 함수

- $\text{Loss} = L_{\text{actor}} + 0.5 \cdot L_{\text{critic}} - 0.01 \cdot E$
- Actor Loss : Clipped PPO Objective
(정책이 급격하게 바뀌는 것 방지)
$$L_{\text{actor}} = -E_t[(A_t \cdot \log \pi_{\theta}(a_t | s_t))]$$
- Critic Loss : Value Function Loss
(상태의 실제 return 과 예측 value 간 오차 (MSE))
$$L_{\text{critic}} = (V_{\theta}(s_t) - R_t)^2$$
- Entropy : Exploration Term
(정책의 엔트로피(탐험 장려))

실험

실험 3 : 온라인 A2C



- ✓ 50개의 데이터셋을 사용하여 A2C 알고리즘으로 온라인 학습 진행
- ✓ A2C는 에피소드마다 업데이트가 이루어져 학습 변화를 세밀하게 확인할 수 있으나 변동성이 PPO보다 크게 나타남
- ✓ 전반적으로 상승하는 Return 흐름 확인
- ✓ Actor Loss에서는 변동성이 크게 증가하는 양상 확인
- ✓ Critic Loss와 Entropy는 점진적으로 감소하며, 전체적인 수렴 양상은 PPO와 유사하게 나타남

실험

실험 4 : 온라인 DQN

학습 하이퍼파라미터

- num_episodes : 1000 (총 학습 에피소드 수)
- Learning Rate: 0.003
- Batch Size : 32
- Buffer Size : 10000
- Max Steps : 5 (에피소드 당 최대 스텝 횟수)
- Gamma : 0.95 (스텝당 보상 할인율)
- GAE Lamda : 0.95
- target update frequency: 10
(10개 에피소드마다 업데이트)
- epsilon_decay : 0.995 (탐색 감소율)
- K Epochs : 3 (배치 재사용 횟수)
- Output Activation : softmax (action 확률 분포)


loss 함수

- MSE loss 사용

$$\text{Loss} = (Q(s_i, a_i) - y_i)^2$$

실험

실험 4 : 온라인 DQN



- ✓ DQN에서는 가치 기반 방식으로 Q-value가 빠르게 안정화되면서 초기 return이 빠르게 증가
- ✓ 학습이 진행될수록 MSE Loss가 지속적으로 감소하며 안정적인 수렴 패턴을 보임
- ✓ 비교적 적은 상호작용에서도 기본적인 성능의 정책을 빠르게 확보할 수 있음을 확인

결론

토의

방향

최근 LLM 기반 에이전트 서비스가 많이 출시되고 있으며,
에이전트 간 최적 선택을 위한 LLM Router 개념의 강화학습 연구도 활발하게 진행되고 있음

아이디어

이러한 연구를 실제 현업에서 적용하기 위해서는 고성능의 인프라가 필요하고
LLM을 강화학습 하기 위한 시간과 비용이 많이 필요함

목표

그래서 본 프로젝트에서는 저비용 인프라 환경에서도 강화학습을 통해
기존 AI 에이전트 서비스의 성능을 향상시킬 수 있는 가능성을 탐색하고자 함

한계

최근 NeurIPS에 채택된 Router-R1 논문을 기반으로 개념적 스케치 진행
(해당 논문은 일반적인 상황에서의 LLM을 강화학습을 통해 최적화 하는 방법)

에이전트

MLP 구조의 간단한 인공신경망으로 정책을 설계하고, 짧은 시간 안에 가능성을 찾기 위해
석 · 박사 과정에서 요구되는 '논문 교정' 태스크를 중심으로 최적화 프로젝트 진행

결론

결론

1. LLM 기반 논문 교정 에이전트의 단계적 의사결정을 강화학습으로 최적화할 수 있는 가능성 보임
2. PPO 기반 정책 학습을 통해 품질 · 비용 · 속도 간 균형 잡힌 전략을 도출함
3. 반복 행동, 불필요한 교정, 과도한 API 호출을 억제하는 보상 설계가 효과적으로 작동하여 효율적인 교정 패턴을 학습함
4. 저품질 텍스트 재가공 기반 데이터셋은 다양한 오류 패턴을 포함하여 정책의 일반화 성능 향상에 기여함

프로젝트 주요 성과




프로젝트 한계



1. 규칙 기반 스코어에 의존하는 평가 방식과 학습에 사용된 제한된 데이터 양으로 인해 실제 품질과의 완전한 정합성 확보에는 한계가 존재함
2. 실제 문서 전체를 활용하기 위해서는 필요한 자원 또한 고비용이 될 수 있음


결론

향후 발전 방향




부록


참고 문헌




Zhang, H., Feng, T., & You, J. (2025, June). Router-r1:
Teaching llms multi-round routing and aggregation via reinforcement learning.



Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., et al. (2025).
Qwen3 Technical Report. *arXiv preprint arXiv:2505.09388*.



Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017).
Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.



Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., ... & Hassabis, D. (2015).
Human-level control through deep reinforcement learning.
Nature, 518(7540), 529–533.



Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., ... & Kavukcuoglu, K. (2016).
Asynchronous methods for deep reinforcement learning.
International Conference on Machine Learning (ICML).

부록

팀원 역할

김진산

1. 프로젝트 구체화 → 레퍼런스 논문 기반으로, 특정 도메인 중심으로 강화학습 설계 (state, Action, Reward)
2. 데이터 수집 크롤링 기능 구현 및 수행
3. 룰 기반 문서 품질 평가 구현
4. 시각화 코드 구현 및 PPT 작성용 그래프 자료와 해석 제공

차시명

1. 레퍼런스 논문 (Router-R1) 구현 → LLM 파인튜닝을 사용하지 않는 방법으로 구현
2. 프로젝트 구체화 내용을 반영하여 오프라인 · 온라인 학습과 다양한 알고리즘(DQN, A2C, PPO) 적용 및 확장을 위한 코드 구조 캡슐화, 추상화 진행
3. 학습 과정의 디버깅을 위한 체크포인트 및 로깅 구현
4. PPT 초안 내용 작성

한다현

1. 프로젝트 구체화 → 레퍼런스 논문 기반으로, 특정 도메인 중심으로 강화학습 설계 (state, Action, Reward)
2. 오프라인 데이터셋 생성 코드 구현 및 수행
3. 문서 품질 평가 검토 및 구체화
4. PPT 내용 구체화 및 디자인

감사합니다

서강대학교 AI · SW 대학원 데이터사이언스 · 인공지능전공

A72040 김진산 | A72080 차시명 | A72085 한다현

팀명 : 외유내강 (겉으론 부드러워 보이나, 내가 강화되고 있음)

<https://github.com/itcasim0/reinforcement-with-lm>